

Lab02_PedroLacerda

Pedro da Costa Lacerda - 258354

1)

```
#As estatísticas suficientes são o número de voos atrasados e o número total de voos avaliados
```

2)

```
library(dplyr)
```

Warning: pacote 'dplyr' foi compilado no R versão 4.5.3

Anexando pacote: 'dplyr'

Os seguintes objetos são mascarados por 'package:stats':

filter, lag

Os seguintes objetos são mascarados por 'package:base':

intersect, setdiff, setequal, union

```
getStats <- function(input, pos) {  
  input %>%  
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%  
    filter(!is.na(ARRIVAL_DELAY), !is.na(YEAR), !is.na(MONTH), !is.na(DAY)) %>%  
    group_by(YEAR, MONTH, DAY, AIRLINE) %>%  
    summarise(  
      voos_atrasados = sum(ARRIVAL_DELAY > 10),  
    )  
}
```

```

    voos_totais = n(),
    .groups = "drop"
  )
}

```

3)

```
library(readr)
```

Warning: pacote 'readr' foi compilado no R versão 4.5.3

```

dados_agrupados_lotes <- read_csv_chunked(
  file = "flights.csv.zip",
  callback = DataFrameCallback$new(getStats),
  chunk_size = 100000,
  col_types = cols_only(
    YEAR = col_integer(),
    MONTH = col_integer(),
    DAY = col_integer(),
    AIRLINE = col_character(),
    ARRIVAL_DELAY = col_double()
  )
)

```

4)

```

computeStats <- function(df) {
  df %>%
    group_by(YEAR, MONTH, DAY, AIRLINE) %>%
    summarise(
      total_atrasados = sum(voos_atrasados),
      total_voos = sum(voos_totais),
      .groups = "drop"
    ) %>%
    mutate(
      Cia = AIRLINE,
      Data = as.Date(paste(YEAR, MONTH, DAY, sep = "-")),
      Perc = total_atrasados / total_voos
    ) %>%
    select(Cia, Data, Perc)
}

```

```
stats_finais <- computeStats(dados_agrupados_lotes)
```

5)

```
library(ggplot2)
```

Warning: pacote 'ggplot2' foi compilado no R versão 4.5.3

```
library(ggcal)
```

```
pal <- scale_fill_gradient(low = "#4575b4", high = "#d73027")
```

```
baseCalendario <- function(stats, cia_interesse) {
```

```
  df_cia <- stats %>%
```

```
    filter(Cia == cia_interesse)
```

```
  calendario <- ggcal(df_cia$Data, df_cia$Perc)
```

```
  return(calendario)
```

```
}
```

```
cAA <- baseCalendario(stats_finais, "AA")
```


```
cDL <- baseCalendario(stats_finais, "DL")
```

```
cUA <- baseCalendario(stats_finais, "UA")
```

```
cUS <- baseCalendario(stats_finais, "US")
```

```
cAA + pal + ggtitle("Percentual de Atrasos (>10 min) - AA")
```

Percentual de Atrasos (>10 min) – AA



```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-08-24 22:56:14 -03"
```